

Matriz de decisión y optimización de costos de IA

Matías Martínez · Entrega Final · Precios por millón de tokens (API oficiales, sep-2026)

1. Matriz de decisión: qué modelo para cada tarea

Tarea del ecosistema	Modelo elegido	Precio (in/out por 1M tk)	Justificación
Redacción de posts cortos con directrices (la tarea de este pipeline: ~700 tk de entrada, ~300 de salida)	GPT-4o-mini  en producción	US\$ 0,15 / 0,60	Tarea simple y acotada: el contexto es pequeño, el formato está fijado por las directrices RAG y el HITL corrige cualquier desliz. Un modelo grande no mejora el resultado de forma perceptible y cuesta 20-25 veces más.
Lectura densa (analizar contratos, informes largos o el historial completo de una marca)	Claude Sonnet	US\$ 3,00 / 15,00	Para documentos extensos que exigen razonamiento y ventana de contexto grande, el costo extra se justifica: un error de interpretación en un contrato cuesta más que el modelo.
Clasificación masiva simple (triage de miles de correos o reseñas)	Claude Haiku o GPT-4o-mini	US\$ 1,00 / 5,00 · 0,15 / 0,60	Tareas de una palabra de salida ("Alta/Baja"): el modelo más barato disponible con max_tokens ≈ 10.
Procesos masivos no urgentes (regenerar 500 piezas, análisis mensual del histórico)	El mismo modelo de la tarea + Batches API	50% de descuento automático	Si nadie espera la respuesta en tiempo real, el lote asíncrono (respuesta en hasta 24 h) reduce cualquier factura a la mitad sin cambiar una línea del prompt.

2. Palancas de ahorro aplicadas en el flujo

- **max_tokens = 400** en la redacción (un post de LinkedIn no necesita más): protege contra respuestas infladas.
- **temperature 0,7** solo porque la tarea es creativa; en tareas de clasificación se usa 0 (respuestas consistentes = menos reintentos).
- **Trigger con filtro por estado**: el flujo solo procesa filas en "Generando", nunca re-procesa piezas ya trabajadas → cero llamadas de IA desperdiciadas.
- **Prefijo estable de prompt**: las directrices van siempre al inicio del bloque de sistema, lo que habilita el caché de prompts del proveedor cuando el prefijo supera el mínimo cacheable (en Anthropic, lecturas de caché al 10% del precio).

3. Costo real estimado del pipeline

Escenario	Cálculo	Costo mensual
Operación actual (30 piezas/mes con GPT-4o-mini)	$30 \times (700 \text{ tk in} \times \$0,15/\text{M} + 300 \text{ tk out} \times \$0,60/\text{M})$ $\approx 30 \times \$0,0003$	≈ US\$ 0,01
Lo mismo con un modelo grande (GPT-4o / Claude Sonnet)	$30 \times \sim \$0,007$	≈ US\$ 0,21
Escenario masivo: 1.000 piezas/mes con GPT-4o-mini + Batches	$1.000 \times \$0,0003 \times 50\%$	≈ US\$ 0,15

Conclusión: elegir el modelo por tarea (y no "el mejor modelo para todo") mantiene el costo de IA de este ecosistema por debajo de un dólar mensual incluso escalando 30 veces el volumen. El costo real

del sistema está en las horas humanas de revisión, y justamente eso es lo que el HITL reduce a un clic por pieza.